

2026 《人工智能导论》大作业

(可参考修订)

任务名称: 可解释的社交媒体谣言检测

完成组号: 12

小组人员: 汪欣雅 姜云曦 苏祎凡 刘雨芯

完成时间: 2026 年 6 月


1. 任务目标

基于社交媒体推文数据集，构建一个可解释的谣言检测系统。系统需输出二分类标签（0：非谣言，1：谣言）并生成一段自然语言判断依据。我们采用 本地监督学习分类器 + BM25 证据检索 + 学校 LLM 解释生成 的复合架构，将分类决策与解释生成解耦，确保分类结果稳定且可解释。


2. 具体内容

(1) 实施方案

系统整体流程如下图所示：



特征工程流水线如下图所示，我们并行提取三类特征后融合：



文本清洗 (`text_features.py`)：URL 替换为 `urltoken`、@提及替换为 `usertoken`、#话题保留为 `hashtagtoken`、移除 `rt` 标记、统一小写。

特征提取：词级 TF-IDF (`max_features=30000`)、字符级 TF-IDF

(`max_features=30000`)、13 维风格统计特征（文本长度、词数、URL/@/#数量、感叹号/问号数、大写字母比例、标点比例、平均词长、重复标点数等）。

分类器 (`improved_classifier.py`)：采用 `LinearSVC` (`C=1.0`, `class_weight='balanced'`)，决策函数值经 `sigmoid` 映射为伪概率，阈值 0.51 输出标签。

证据检索 (`bm25_retriever.py`)：BM25 索引检索与预测标签一致的相似训练样本，仅用作解释证据。

解释生成 (`detection.py` + `llm_client.py`)：构造 System Prompt 限定 LLM 仅解释已固定标签，调用 `deepseek-chat` API 输出 `<reasoning>` 格式的解释。

版本演进：

1.0 版为 BM25+LLM 直接分类（准确率约 0.793）；

2.0 版引入 TF-IDF+MLP 本地分类器（0.8653）；

3.0 版增加清洗与风格特征，替换为 `LinearSVC`，并进行阈值扫描与多模型对比，最终达 0.8753。

(2) 核心代码分析

特征融合 (`improved_classifier.py`)：`_build_features()` 使用 `FeatureUnion` 并行提取三类特征；`_build_pipeline()` 串联特征与 `LinearSVC`；预测时通过 `decision_function` 获取分数并映射为概率。


BM25 检索 (`bm25_retriever.py`)：`update()` 收集训练样本并统计文档频率；`retrieve()` 按 BM25 得分排序，用 `preferred_label` 过滤同标签证据，避免检索错误影响分类。

解释调度 (`detection.py`)：`predict()` 先由分类器获得标签（精确匹配训练集则直接返回），再检索证据，构造 Prompt 调用 LLM，解析 `<reasoning>` 标签作为解释；LLM 失败时触发备用解释。


运行入口 (`run.py`)：逐条 `update()` 训练集，逐条 `predict()` 验证集，每条间隔 6 秒避免 API 限流，结果保存至 `results/prediction_results_*.csv`。

(3) 检测结果分析（正确率等）

Style+LinearSVC 在准确率（87.53%）、精确率（91.39%）和 F1（84.66%）上均最优。精确率显著高于召回率，说明模型判断保守——预测为谣言的样本绝大多数确为谣言（误报仅 13 例），但会漏掉部分谣言（漏报 37 例）。相比 TF-IDF+MLP，改进模型准确率提升 1 个百分点，F1 提升 1.1 个百分点，误报从 16 降至 13，漏报从 38 降至 37。深度模型表现不及传统方法，可能因数据集规模较小，预训练模型微调效果不佳。




各模型准确率与 F1 的对比柱状图如下：



（4）判断依据的分析（可解释性等）

系统从三个层面提供可解释性：



特征可解释：统计特征具有直观语义，便于理解决策依据。

证据可追溯：BM25 检索的相似样本提供实例级支撑，用户可查看“与哪些已知样本相似”。

自然语言解释：LLM 生成 2~4 句判断依据，System Prompt 严格限定其不改变标签，确保解释忠实于分类结果。示例解释：“该推文包含多个外部链接和大量感叹号，符合谣言传播的典型模式。与训练集中标签为‘1’的样本高度相似（BM25 得分 0.876），且置信度达 0.92，因此判定为谣言。”

注：对于检测结果，尽可能给出分析图

3. 工作总结

（1）收获、心得

通过本次大作业，我们完整经历了从特征工程、模型选型到系统集成的 AI 开发流程。深刻体会到：特征工程的质量往往比模型复杂度更重要——简单的 TF-IDF+统计特征+LinearSVC 在谣言检测任务上超越了深度模型。“分类与解释解耦”的架构设计让我们认识到，将敏感决策交给可控的本地模型，将开放生成交给 LLM，既能保证分类稳定性，又能获得高质量解释。


（2）遇到问题及解决思路

LLM 被检索证据带偏：早期 LLM 同时负责分类和解释，BM25 检索错误样本会改变分类。解决：分类由 LinearSVC 决定，LLM 仅解释已固定标签，BM25 仅提供证据。
深度模型效果不佳：BiLSTM 和 TextCNN 不如传统方法。解决：引入风格统计特征，改用 LinearSVC，取得最优效果。

LLM 输出不稳定：不同 Prompt 导致解释质量波动。解决：在 System Prompt 中明确限定<reasoning>输出格式，并增加备用解释机制。

4. 课程建议

建议在课程中增加模型安全与鲁棒性实践环节。针对本项目，我们规划了以下低成本安全防御方向：



对抗样本防御：在预处理阶段引入字符归一化，将视觉混淆字符（如 b0mb→bomb）映射为 ASCII 标准，压缩过度重复标点，维持 TF-IDF 特征分布一致性。

数据投毒监控：利用训练集词频统计构建罕见词黑名单，预测时若输入含异常高比例罕见词则触发安全警告，在 LLM Prompt 中提示用户注意风险。

Prompt 注入防护：在 System Prompt 中明确限定 LLM 仅将用户输入视为待分析材料而非可执行命令，防止越狱指令操控解释内容。

上述改进可在不重新训练核心分类器的前提下，显著提升系统面对恶意干扰时的鲁棒性。

5. 组内分工：

成员	分工
汪欣雅	1.0 版本代码（基本逻辑+跑通）
姜云曦	2.0 版本代码（增加/改进结构）
苏祎凡	3.0 版本代码（调参、优化 Prompt、尝试不同 LLM）
刘雨芯	基于最终代码和结果撰写报告